CNN 이미지 분석을 활용한 주가차트 정보의 예측력 평가

2026 년 03 월 17 일

1 데이터

2026 년 03 월 13 일 현재 KOSPI 200 구성 종목 전체를 기준으로, 2000 년 01 월 04 일 부터 2026 년 03 월 13 일 까지의 일별 시가, 고가, 저가, 종가 및 거래량 데이터를 야후 파이낸스(https://finance.yahoo.com)에서 추출한다. 200 개 종목 중 최소 데이터 수를 충족하는 199 개 종목이 분석 대상이다.

데이터의 최초 시점부터 2018 년 말 까지를 CNN 모형의 훈련 기간으로 설정하고, 2019 년 초 부터 2026 년 03 월 13 일 까지를 표본 외 테스트 기간으로 설정한다. 이 분할은 Gu, Kelly, and Xiu (2020) 의 시간 순서 기반 분할 원칙을 따른다.

표본 기간이 2000 년대 초부터 시작됨으로써, 2003 년 신용카드 부실에 따른 내수 침체기, 2008 년 글로벌 금융위기 등과 같이 시장 변동성이 극단적으로 확대된 국면이 모두 포함된다. 이러한 다양한 시장 환경의 포함은 CNN 모형이 특정 시장 국면에 과적합되지 않고 일반화된 패턴을 학습하는 데 기여한다. 또한 평가 기간에도 2020 년 코로나19 팬데믹 급락, 2022 년 글로벌 긴축에 따른 주가 하락, 2025 - 2026 년 반도체 및 AI 슈퍼사이클과 상법 개정, 배당소득 분리과세 등의 제도 개편에 따른 KOSPI 6000 기록 등 극단적인 상승과 급락이 교차하는 다양한 시장 국면이 포함된다. 이러한 급변동 환경에서는 과거 학습이 성공적으로 이루어지더라도 우수한 예측 성능을 기대하기 어려울 수 있으나, 오히려 모형이 시장의 불규칙한 변동 국면에서도 방향을 올바르게 예측할 수 있는지를 검증하기에는 적절한 조건을 제공한다.

2 이미지 생성

2.1 시장 데이터의 이미지 표현

Jiang, Kelly, and Xiu (2023) 의 방법론에 따라, 각 거래일에 직전 20거래일의 시장 데이터를 사용하여 흑백 이미지를 생성한다. 배경은 검정(픽셀 값 0), 가격과 거래량 등 시각적 객체는 흰색(픽셀 값 255)으로 표현하며, RGB 색상 정보를 사용하지 않고 2차원 픽셀 행렬에 집중한다. 이미지의 크기는 높이 64픽셀, 너비 60픽셀이다. 하루당 3픽셀 너비를 차지하므로, 20일 이미지의 너비는 $20 \times 3 = 60$ 픽셀이 된다. 3픽셀의 구성은 왼쪽 열이 해당 일의 시가 틱, 가운데 열이 고가-저가 수직 바, 오른쪽 열이 종가 틱이다[1].

야후 파이낸스 데이터에서 OHLC가 모두 동일하고 거래량이 0인 날은 실제 비거래일(공휴일 등)이 데이터에 잘못 포함된 것이므로, 이미지 생성 전에 거래량 0인 날을 제거한다[2]. 이를 통해 이동평균 산출과 윈도우 구성이 실제 거래일 기준으로 이루어진다.

모든 이미지에 이미지 스케일링을 적용한다. 20일간 가격의 최고가를 이미지 상단(행 0)에, 최저가를 이미지 하단(행 63)에 대응시켜, 모든 시점의 이미지가 동일한 척도를 갖도록 정규화한다. 이러한 정규화는 서로 다른 가격 수준의 종목 간에도 패턴의 형태적 유사성을 비교 가능하게 하며, Jiang et al. (2023) 이 보인 바와 같이 CNN의 예측력을 크게 향상시킨다

2.2 9단계 이미지 구성

본 연구의 핵심 설계는 차트에 담기는 정보를 9가지 조합으로 구성하여, 각 정보 요소의 한계 기여를 비교하는 것이다. 가격 표현 방식(종가선 또는 OHLC), 거래량, 이동평균선(20일 단독 또는 20일+60일 이중)의 조합에 따라 다음과 같이 이미지를 구성한다.

1단계는 종가 선 그래프만으로 구성된 이미지이다. 각 날의 종가를 가운데

1) 시가 틱(tick)과 종가 틱은 각각 1픽셀의 점으로 표현된다. 시가가 왼쪽, 종가가 오른쪽에 위치하므로, 종가가 시가보다 높으면(상승일) 오른쪽 틱이 왼쪽 틱보다 위에 찍히고, 그 반대이면(하락일) 아래에 찍힌다.

2) KOSPI 200 종목에서 거래량이 0이면서 정상 거래일인 경우(극단적 비유동 종목)는 거의 발생하지 않으므로, 이 처리가 유효 데이터를 손실시킬 가능성은 무시할 수 있다.

열에 점으로 찍고, 인접한 점들을 브레젠햄 직선 알고리즘[3]으로 연결한다. 가격의 방향적 추세 정보만 포함하며, 가장 단순한 기술적 분석의 기초에 해당한다.

2단계는 OHLC 바 이미지이다. 일별 시가, 고가, 저가, 종가를 3픽셀 너비의 바로 표현한다. 종가 선 그래프에는 없는 일중 가격 범위와 시가-종가 관계(상승일과 하락일의 구분)가 추가된다. Parkinson (1980) 이 제시한 바와 같이, 일별 고저 범위는 일별 주가 변동성의 추정치를 제공하므로, 이 단계에서 변동성 정보가 내재적으로 포함된다.

3단계는 종가선에 거래량 바를 추가한 이미지이다. 1단계와 비교하면 거래량 단독의 한계 기여를 분리할 수 있다.

4단계는 OHLC 바에 거래량 바를 추가한 이미지이다. 이미지의 하단 5분의 1(13픽셀)에 거래량 바를, 상단 5분의 4(51픽셀)에 가격 차트를 배치한다. 20일 중 최대 거래량이 거래량 영역의 전체 높이를 차지하도록 스케일링하고, 나머지 날은 비례하여 축소한다. 각 날의 거래량 바는 가운데 열에 이미지 하단으로부터 위로 수직선을 그려 표현한다.

5단계는 종가선에 20일 이동평균선을 추가한 이미지이다[4]. 각 날의 가운데 열에 이동평균 값을 점으로 찍고, 인접한 점들을 브레젠햄 직선으로 연결하여 곡선을 형성한다.

6단계는 OHLC 바에 20일 이동평균선을 추가한 이미지이다. 4단계(OHLC+거래량)와 비교하면, 거래량과 이동평균선 중 어느 것이 OHLC에 더 유용한 보완 정보인지를 직접 비교할 수 있다.

7단계는 종가선에 20일과 60일 이동평균선을 동시에 추가한 이미지이다. 단기 이동평균선과 장기 이동평균선의 교차가 기술적 분석에서 골든크로스 또는 데드크로스로 알려진 추세 전환 신호를 시각적으로 형성한다.

8단계는 OHLC 바에 거래량과 20일 이동평균선을 추가한 이미지이다.

---

3) 브레젠햄 직선 알고리즘(Bresenham's line algorithm). 정수 픽셀 격자 위에서 두 점을 잇는 직선을 그릴 때, 어떤 픽셀을 활성화해야 시각적으로 가장 자연스러운 직선이 되는지를 정수 연산만으로 결정하는 고전적 컴퓨터 그래픽스 알고리즘이다. 이동평균선 연결에도 동일한 알고리즘을 사용한다.

4) 후행(trailing) 이동평균은 해당 행을 포함하여 이전 20개 거래일의 종가 평균으로 산출된다. 데이터 초반의 윈도우에서는 이동평균이 아직 산출되지 않은 날(NaN)이 포함될 수 있으며, 이 경우 해당 날의 이동평균 점은 건너뛰고 유효한 점들만 연결하여 선을 그린다. 이러한 불완전한 이미지는 종목당 약 19개(MA20의 경우) 또는 약 59개(MA60의 경우)로, 전체 이미지 수 대비 미미하다.

9단계는 OHLC 바에 거래량, 20일 및 60일 이동평균선을 모두 추가한 이미지로, 투자자가 실제로 참조하는 가장 풍부한 차트에 해당한다.

아래 그림은 KOSPI 200 구성 종목 중 임의로 추출한 하나의 종목에 대해 특정 시점의 9단계 이미지를 생성한 예시이다. 1행은 기본 가격 표현에서 거래량 추가로의 전개를, 2행은 OHLC+거래량과 단일 이동평균선 조합을, 3행은 이중 이동평균선과 복합 구성을 보여준다.

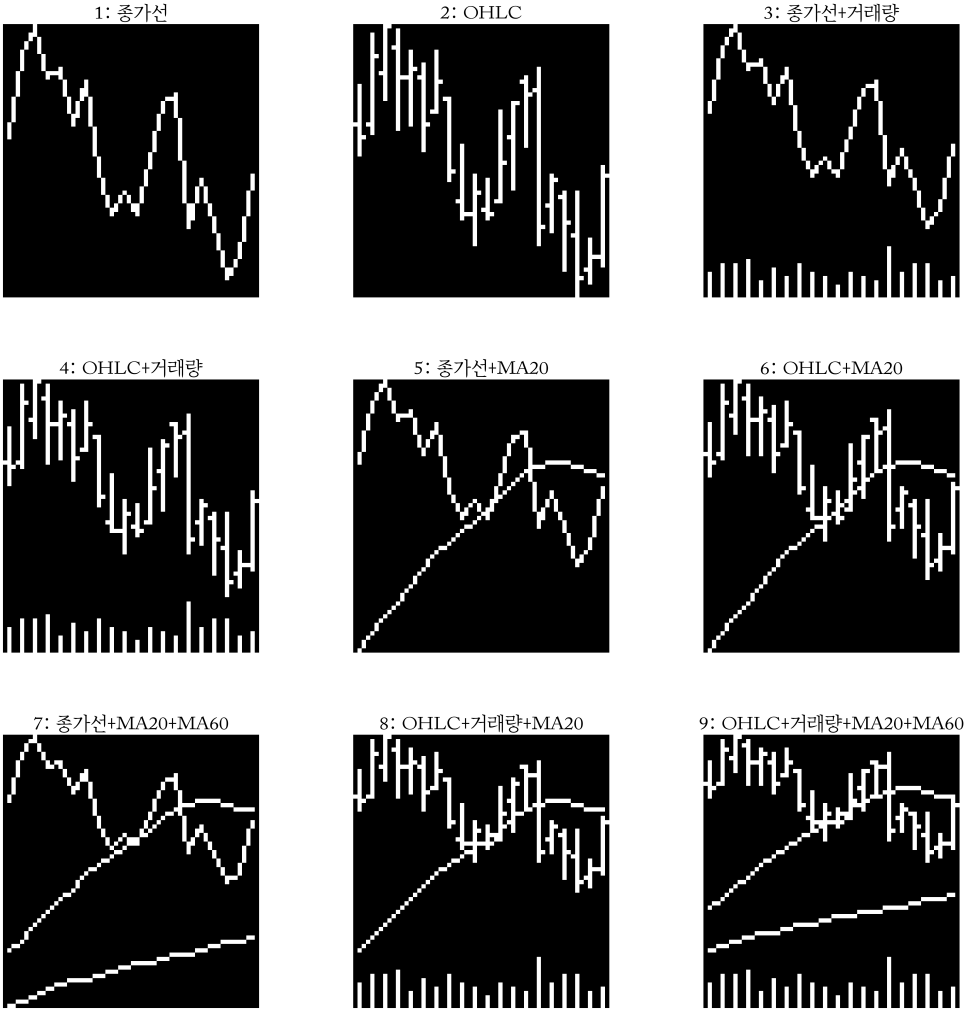

그림 1: 엔씨소프트(036570), 2017-09-12 - 2017-10-17

2.3 이미지 생성 방식

이미지 생성은 훈련 기간과 테스트 기간에서 서로 다른 방식으로 적용된다.

훈련 기간에서는 이동 윈도우(rolling window) 방식을 사용한다. 매 거래일마다 1일씩 앞으로 이동하면서 직전 20거래일의 이미지를 생성한다. 인접한 두 이미지는 19일분의 데이터가 겹치고 1일분만 다르다. 이러한 중첩은 CNN에 충분한 학습 데이터를 제공하기 위한 것이며, 9단계 각각에 대해 528,593개의 훈련 이미지가 생성된다.

테스트 기간에서는 20거래일 간격의 비중첩 방식으로 이미지를 활용한다. 이는 실제 매매 전략의 리밸런싱 주기와 일치한다. 보유기간 20거래일이 종료되는 시점에서 새 이미지를 생성하고, CNN이 산출한 상승 확률에 따라 매수 또는 현금 보유를 결정한다. 따라서 테스트 기간의 평가에 실제로 사용되는 이미지는 서로 겹치지 않는다.

2.4 레이블 산출

각 이미지의 레이블은 기준일로부터 20거래일 후의 종가 수익률에 기반하여 산출한다. 수익률이 양이면 $y = 1$(상승), 음이면 $y = 0$(하락)으로 부여한다. 이 이진 레이블은 CNN의 분류 목표가 되며, 모형의 출력은 $y = 1$에 대한 확률의 추정치이다.

3 CNN 모형

3.1 아키텍처

3개의 빌딩 블록으로 구성된 CNN을 사용한다(Goodfellow, Bengio, and Courville, 2016). 각 블록은 합성곱(convolution), 배치 정규화(batch normalization), 비선형 활성화(leaky ReLU), 맥스 풀링(max pooling)의 순서로 연산을 수행한다. 블록별 필터 수는 32, 64, 128이다.

1번째 블록(필터 32개)은 이미지 전체를 32가지 관점에서 동시에 스캔하여, OHLC 바의 길이(일별 변동성), 바 간 간격(가격 변화 속도), 거래량 바의 높낮이 등 단순한 국소 패턴을 탐지한다. 2번째 블록(필터 64개)은 1번째 블록의 출력을 입력으로 받아, 단순 패턴의 조합을 탐지한다. 예를 들어, 바 길이가 점점 짧아지면서 이동평균선에 접근하는 패턴 등이 이에 해당한다. 3번째 블록(필터 128개)은 더 복잡한 다층 패턴을 탐지한다. 예를 들어, 하락 추세 중 거래량이 급증한 뒤 이동평균선 근처에서 바 길이가 축소되는 패턴은 기술적 분석에서 추세 전환 신호에 해당하는 복합 패턴이다. 각 블록의 합성곱 필터는 3×3 크기이지만,

맥스 풀링에 의해 공간 차원이 블록마다 절반으로 축소되므로, 깊은 블록일수록 원본 이미지의 더 넓은 영역에 해당하는 패턴을 인식하게 된다[5].

3개 블록을 거치면 64×60 픽셀의 원본 이미지가 128장의 8×7 특징 맵으로 변환된다. 이 특징 맵을 7,168개의 1차원 벡터로 평탄화(flatten)한 뒤, 128개 뉴런의 완전 연결 레이어를 거쳐 최종적으로 2개의 출력(하락, 상승)을 산출한다. 소프트맥스 함수를 적용하면 향후 20거래일 수익률이 양(+)일 확률이 출력된다.

3.2 훈련 절차

Gu et al. (2020) 의 절차를 따른다. 훈련 데이터를 70:30의 비율로 무작위 분할하여, 전자를 학습용으로, 후자를 검증용으로 사용한다. Jiang et al. (2023) 에 따르면, 이러한 무작위 분할은 장기 강세 또는 약세 시장 변동에 의한 상승/하락 레이블의 불균형을 완화하는 데 도움이 된다. 검증 세트는 모형의 가중치 갱신에는 관여하지 않으며, 매 에포크마다 검증 손실을 산출하여 조기 중단 시점을 결정하는 데만 사용된다.[6]

예측 분석을 분류 문제로 처리하여, 훈련 단계에서는 교차 엔트로피 손실함수를 최소화한다.

$$L(y, \hat{y}) = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$$

여기서 $\hat{y}$ 는 CNN의 소프트맥스 출력이다. 예측 확률이 레이블과 정확히 일치하면 손실함수는 0이며, 그렇지 않으면 양의 값을 갖는다.

정규화 기법으로는 Xavier 초기화[7], Adam 알고리즘(초기 학습률 1×10^{-5}, 배치 크기 128), 각 블록 내 배치 정규화, 완전 연결 레이어에 대한 50% 드롭아웃을

5) 이를 수용 영역(receptive field)이라 한다. 1번째 블록은 원본 이미지의 3×3 픽셀을 직접 관찰하지만, 2번째 블록은 맥스 풀링에 의해 축소된 특징 맵에서 3×3을 관찰하므로 원본 기준 약 6×6 영역에 해당하며, 3번째 블록은 약 12×12 영역에 해당한다.

6) 이 분할은 교차검증(cross-validation)이 아니라 1회의 무작위 분할이다. 5회 독립 훈련에서 매 run마다 서로 다른 난수 시드를 사용하므로 70:30 분할의 구성이 run마다 달라지며, 이를 통해 특정 분할에 대한 결과의 의존성이 완화된다.

7) Xavier 초기화(Glorot and Bengio, 2010) 는 입력과 출력 뉴런 수를 고려하여 가중치의 초기값 범위를 설정함으로써, 학습 초기부터 신호의 분산이 레이어 간에 안정적으로 유지되도록 한다.

적용한다. 검증 표본의 손실함수가 연속 2에포크 동안 개선되지 않으면 훈련을 중단하는 조기 중단(early stopping)을 사용한다.

CNN 최적화는 확률적 경사하강법에 기반하므로, 초기 가중치와 배치 구성의 무작위성에 따라 결과가 달라질 수 있다. 이를 감안하여 Gu et al. (2020) 의 방식에 따라, 동일한 구조의 CNN을 5회 독립적으로 훈련하고 예측 확률을 평균한다. 9단계 이미지 각각에 대해 이 절차를 적용하므로, 총 $9 \times 5 = 45$회의 CNN 훈련이 수행된다.

Jiang et al. (2023) 에서는 모든 종목의 이미지를 하나의 풀(pool)로 통합하여 단일 CNN을 훈련하는 풀링 모형을 채택하고 있다. 본 연구에서도 이를 기본으로 채택한다. 이미지 스케일링에 의해 모든 종목의 가격이 0 - 1 범위로 정규화되어 있으므로 CNN은 개별 종목의 고유한 차이를 넘어 주가 차트 패턴의 일반화된 형태적 특성을 학습한다.[8)]

4 분석 결과

4.1 분류 정확도

아래 표는 9단계 이미지 구성별로 CNN의 표본 외 테스트 정확도[9)](5회 독립 훈련의 예측 확률 평균에 기반한 이진 분류 정확도)를 보고한다.

8) 투자자가 차트를 관찰하는 실제 행태를 고려하면 종목별 모형의 적용도 검토할 수 있다. 투자자는 특정 종목의 차트를 보면서 해당 종목의 방향을 판단하는 것이지, 그 패턴을 이용하여 또 다른 종목의 투자 기회를 모색한다고 기대하는 것은 다소 비현실적일 수 있다. 종목마다 변동성 특성, 거래량 패턴, 업종 고유의 가격 움직임이 상이하므로, 투자자의 관점에서는 종목별 차트 분석을 통해 이러한 개별 특성을 더 정확히 포착하고자 노력한다고 보는 것이 합리적이다. 다만 종목별로 모형을 분리하여 학습할 경우 종목당 훈련 이미지 수가 제한적이므로 과적합의 위험이 있을 수 있으며, 학습에 소요되는 시간이 종목 수에 비례하여 급격히 증가한다.

9) 분류 정확도(accuracy)는 전체 테스트 이미지 중 CNN의 예측(상승 또는 하락)이 실제 레이블과 일치한 비율로 정의된다. 다만 이 지표는 상승/하락의 비대칭성을 반영하지 못한다. 예를 들어 테스트 기간의 실제 상승 비율이 50.2%인 상황에서 모든 이미지를 상승으로 예측하더라도 정확도가 50.2%에 달한다. 상승 예측 비율이 실제보다 높게 나타난 것은 모형이 상승 쪽으로 편향되어 있음을 시사한다. 이러한 한계를 보완하기 위해 AUC 등 추가적인 평가 지표를 함께 검토한다.

표 1: 9단계 이미지 구성별 CNN 분류 정확도

이미지 구성	테스트 정확도	상승 예측 비율
종가선	50.54%	80.7%
OHLC	50.84%	73.5%
종가선+거래량	50.58%	75.1%
OHLC+거래량	50.68%	75.0%
종가선+MA20	51.12%	60.7%
OHLC+MA20	51.03%	69.7%
종가선+MA20+MA60	50.87%	61.6%
OHLC+거래량+MA20	50.97%	73.4%
OHLC+거래량 +MA20+MA60	50.91%	62.4%

종가 선 그래프만으로 구성된 1단계의 테스트 정확도는 50.54% 로, 사실상 무작위 추측(50%)과 구별되지 않는다. 이는 효율적 시장 가설 하에서 종가의 방향적 추세만으로는 미래 수익률을 예측할 수 없다는 것과 일치한다.

9단계 전체에서 가장 높은 정확도를 보이는 것은 종가선+MA20(51.12%)이다. 모든 정보를 결합한 9단계(50.91%)가 최고치를 기록하지 않았다는 점은, 정보 요소의 추가가 반드시 예측력 향상으로 이어지지 않음을 보여준다.

4.2 정보 요소별 한계 기여

이동평균선의 기여가 가장 두드러진다. 종가선에 MA20을 추가하면(1단계→5단계) 정확도가 +0.59%p 개선되어, 9단계 구성 중 최고 정확도를 기록한다. OHLC에 MA20을 추가하는 경우(2단계→6단계)에도 +0.18%p 의 개선이 나타난다. 이동평균선이 현재 가격 수준에 대한 기준점을 제공함으로써 CNN의 방향 판단에 유효한 정보를 제공하는 것으로 해석된다.

반면 60일 이동평균선의 추가는 오히려 정확도를 낮춘다. 종가선+MA20에 MA60을 추가하면(5단계→7단계) -0.25%p, OHLC+거래량+MA20에 MA60을 추가하면(8단계→9단계) -0.05%p 로 소폭 하락한다. 두 이동평균선이 동시에 표시됨으로써 CNN이 유사한 곡선 사이의 미세한 차이에서 잡음을 학습하거나,

64×60 픽셀의 제한된 해상도 안에서 중첩된 선들이 오히려 패턴 인식을 방해하는 것으로 추정된다.

거래량의 한계 기여는 기대에 미치지 못한다. 종가선에 거래량을 추가하면 (1단계→3단계) +0.04%p, OHLC에 거래량을 추가하면(2단계→4단계) -0.16%p에 그친다.

결론적으로 KOSPI 200에서 CNN 예측력에 가장 크게 기여하는 정보 요소는 이동평균선(MA20)이며, OHLC가 이를 보완한다. 그러나 MA60과 거래량의 추가는 정확도 개선에 기여하지 못하였다. MA60이 MA20과 중복되는 정보를 제공하거나 거래량이 저해상도 이미지 안에서 오히려 시각적 혼잡을 유발할 수 있기 때문이라고 추정한다. 정보 요소의 추가가 독립적인 예측 정보를 제공하지 않는 한, 오히려 잡음을 유발하여 정확도를 제한할 수 있음을 시사한다.

4.3 매매 전략 시뮬레이션

분류 정확도를 경제적 의미로 전환하기 위해, Jiang et al. (2023) 의 방법론에 따라 10분위 long-short 포트폴리오 전략을 구성한다. 전략의 리밸런싱 주기는 20거래일이다. 각 리밸런싱 시점에서 CNN이 산출한 상승 확률을 기준으로 전체 종목을 오름차순 정렬한 뒤 10분위로 나눈다. 최상위 분위(D10)를 동일가중으로 매수(long)하고 최하위 분위(D1)를 동일가중으로 매도(short)한다. 전략의 수익률은 매수 레그의 평균 수익률에서 매도 레그의 평균 수익률을 차감한 H-L 스프레드[10]로 정의된다. 이 구성은 시장 전체의 방향에 대한 순 노출을 상쇄하므로, H-L 스프레드가 양(+)이라는 것은 CNN이 상대적으로 상승 가능성이 큰 종목과 작은 종목을 유의미하게 구분하고 있음을 의미한다. 비교 기준으로 전 종목 동일가중 매수보유(buy-and-hold) 전략을 함께 보고한다.

거래 비용은 한국거래소 기준으로 매수 시 수수료 0.015%, 매도 시 수수료 0.015% + 증권거래세 0.2%를 반영한다[11]. 매수 레그와 매도 레그 각각에서 리

10) H-L 스프레드(High-minus-Low spread). CNN 상승 확률 기준 최상위 분위(High) 포트폴리오의 수익률에서 최하위 분위(Low) 포트폴리오의 수익률을 차감한 값이다. Jiang et al. (2023)의 Table I에서 동일한 방식으로 보고된다.

11) 매수 레그에서 신규 진입 종목에는 매수수수료, 청산 종목에는 매도수수료 + 증권거래세가 적용된다. 매도 레그에서 신규 공매도 진입에는 매도수수료 + 증권거래세, 환매 청산에는 매수수수료가 적용된다. 이전 리밸런싱과 동일한 분위에 잔류하는 종목에는 비용이 발생하지 않는다.

밸런싱에 따라 포지션이 변경되는 종목에 대해서만 비용을 부과한다. 무위험 수익률은 0으로 가정한다.

연율화 수익률은 테스트 기간 전체의 누적 수익률 R_{cum} 으로부터 $R_{\text{ann}} = R_{\text{cum}}^{252/n} - 1$ 로 산출한다. 여기서 n 은 총 거래일수, 252는 연간 거래일수이다. 연율화 샤프비율[12]은 일별 수익률의 평균 $\bar{r}$ 과 표준편차 σ_r 로부터 Sharpe $= (\bar{r}/\sigma_r) \times \sqrt{252}$ 로 산출한다. 최대 낙폭(MDD, maximum drawdown)은 누적 수익률 경로의 고점 대비 최대 하락 폭으로, 전략이 경험할 수 있는 최악의 손실을 측정한다.

4.4 종합 성과 지표

아래 표는 9단계 이미지 구성별로 CNN 매매 전략과 매수보유 전략의 성과 지표를 보고한다.

H-L 스프레드의 연율화 수익률은 9개 단계 중 6개에서 음(-)이다. 양(+)의 수익률을 보이는 것은 5단계(종가선+MA20, 2.74%), 8단계(OHLC+거래량+MA20, 2.21%), 7단계(종가선+MA20+MA60, 0.34%)뿐이다. 이 중 가장 높은 샤프비율은 5단계의 0.255 이다. 반면 매수보유 전략은 연율화 수익률 17.86%, 샤프비율 0.919 로, 모든 단계의 H-L 전략을 압도한다.

가장 풍부한 차트 정보를 결합한 9단계(OHLC+거래량+MA20+MA60)의 H-L 수익률이 -4.74% 로 전체 단계 중 최저치를 기록하였다는 점은 주목할 만하다. 반면 분류 정확도와 H-L 수익률 모두에서 가장 양호한 성과를 보인 것은 5단계(종가선+MA20)이다. 이는 이미지 윈도우를 20거래일로 설정한 본 연구의 이미지 구조와 관련이 크다고 판단한다. 20일 이동평균선은 각 시점에서 직전 20거래일의 종가 평균이므로 윈도우 내 가격 경로와 자연스러운 대응 관계를 형성하며, 현재 가격이 기간 평균 대비 어디에 위치하는지를 직접적으로 보여주는 기준선으로 기능한다.[13] CNN은 이 기준선과 가격의 상대적 위치를 쉽게 인식할 수 있으나, 윈도우 밖 과거 가격에 의존하는 60일 이동평균선은 현재 주

12) 샤프비율(Sharpe ratio). 단위 위험당 초과 수익률을 나타내며, 전략의 위험 조정 성과를 비교하는 데 사용된다.

13) Jiang et al. (2023) 은 5일 윈도우에 MA5, 20일 윈도우에 MA20, 60일 윈도우에 MA60을 대응시키는 방식으로 이미지를 구성한다. 이미지 윈도우를 60거래일로 확장한다면 MA60이 유효한 기준선이 될 가능성이 있다고 예상한다. 현재의 20일 윈도우에서 MA20이 부각되는 것은 이동평균의 본질적 우월성이라기보다 윈도우 길이와 이동평균 기간의 일치에 기인하는 것이라고 판단한다.

가와의 시각적 관계가 모호하여, 추가적 정보가 오히려 예측 성능을 저해하는 소음으로 기능하고 있다고 판단한다.

거래량은 주가 예측에 크게 기여하지 못하고 있다. KOSPI 200 구성 종목은 모두 대형주로서 유동성이 풍부하고 거래량 패턴이 종목 간에 유사하다. KOSPI 200은 유동성 수준에서 종목 간 편차가 작아 거래량이 횡단면적으로 차별화된 정보를 제공하기 어렵다고 판단한다.

H-L 스프레드가 음(-)이라는 것은 CNN이 상승 확률이 높다고 판단한 종목(D10)이 오히려 낮다고 판단한 종목(D1)보다 성과가 나빴음을 의미한다. 이는 CNN의 횡단면적 종목 선별 능력이 KOSPI 시장에서 유효하지 않음을 시사한다.

최대 낙폭의 관점에서, H-L 전략의 MDD는 -26.78%(4단계)에서 -48.48%(3단계)까지 분포한다. 시장 중립적 long-short 구성임에도 매수보유(-49.94%)에 근접하는 낙폭을 경험하는 단계가 다수 존재한다는 것은, CNN이 상승으로 예측한 종목이 하락하고 하락으로 예측한 종목이 오히려 상승하는 양방향 오류가 동시에 발생하였음을 의미한다.

표 2: 9단계 이미지 구성별 10분위 long-short 전략 성과

이미지 구성	정확도	H-L 수익률	BH 수익률	H-L 샤프	BH 샤프	H-L MDD	BH MDD
I. 종가선	50.54%	-1.60%	17.80%	-0.035	0.916	-45.40%	-49.94%
II. OHLC	50.84%	-1.85%	17.86%	-0.036	0.919	-34.14%	-49.94%
III. 종가선+거래량	50.58%	-3.80%	17.80%	-0.175	0.916	-48.48%	-49.94%
IV. OHLC+거래량	50.68%	-0.07%	17.81%	0.074	0.917	-26.78%	-49.94%
V. 종가선+MA20	51.12%	2.74%	17.98%	0.255	0.924	-27.64%	-49.94%
VI. OHLC+MA20	51.03%	-1.53%	17.80%	-0.024	0.916	-40.72%	-49.94%
VII. 종가선 +MA20+MA60	50.87%	0.34%	17.86%	0.096	0.919	-36.05%	-49.94%
VIII. OHLC+거래량 +MA20	50.97%	2.21%	17.80%	0.217	0.916	-30.95%	-49.94%
IX. OHLC+거래량 +MA20+MA60	50.91%	-4.74%	17.86%	-0.239	0.919	-45.22%	-49.94%

4.4.1 테스트 기간 조정에 따른 성과 비교

종합주가지수(KOSPI)는 2024년 말 2,397에서 2026년 3월 초 6,165까지 약 세 배 상승하였다. 이는 2018년말 이전의 CNN의 훈련 기간에서 경험하지 못한 이례적 상승이다. 따라서 CNN의 예측력 저하가 모형의 본질적 한계에 기인하는 것인지, 훈련 과정에서 경험하지 못한 극단 국면에 대한 외삽 실패에 기인하는 것인지 구분하기 어렵다. 이를 확인하기 위해 주가 급등이 본격화되기 이전인 2024년 12월 말까지를 테스트 기간으로 한정하여 성과를 재평가한다. 훈련된 모형과 예측 결과는 그대로 사용하며, 테스트 기간의 날짜 필터링만 적용한다.

표 3: 10분위 long-short 전략 성과(테스트 기간 2024년 말 한정)

이미지 구성	정확도	H-L 수익률	BH 수익률	H-L 샤프	BH 샤프	H-L MDD	BH MDD
I. 종가선	49.66%	-1.30%	8.90%	-0.021	0.525	-44.95%	-49.94%
II. OHLC	50.22%	-1.61%	8.97%	-0.027	0.528	-34.14%	-49.94%
III. 종가선+거래량	49.78%	-0.64%	8.90%	0.035	0.525	-40.01%	-49.94%
IV. OHLC+거래량	49.97%	1.21%	8.97%	0.155	0.528	-26.41%	-49.94%
V. 종가선+MA20	50.80%	1.42%	9.08%	0.169	0.533	-24.95%	-49.94%
VI. OHLC+MA20	50.54%	-5.12%	8.90%	-0.272	0.525	-37.33%	-49.94%
VII. 종가선 +MA20+MA60	50.57%	2.36%	8.97%	0.232	0.528	-29.10%	-49.94%
VIII. OHLC+거래량 +MA20	50.33%	-0.86%	8.90%	0.023	0.525	-27.06%	-49.94%
IX. OHLC+거래량 +MA20+MA60	50.59%	-1.12%	8.97%	0.004	0.528	-32.04%	-49.94%

테스트 기간을 2024년 말까지로 한정하면 분류 정확도에서 변화가 관찰된다. 1단계(종가선)의 정확도가 49.66% 로 50% 미만으로 하락하여 무작위 추측 이하가 된다. 앞서 분석에서 분류 정확도가 50%를 상회한 것은 2025 - 2026년에 대부분의 종목이 실제로 상승하면서 상승 편향이 있는 CNN의 예측과 우연히 부합했을 가능성이 있다. 5단계(종가선+MA20)는 정확도 50.80% 로 여전히 전 단계 중 최고치를 유지한다.

H-L 수익률에서 두 가지 변화가 주목된다. 첫째, 9단계의 H-L 수익률이 전체 기간 -4.74% 에서 -1.12% 로 개선되고, 샤프비율도 -0.239 에서 0.004 로 0 근처까지 회복된다. 2025 - 2026년 급등 구간이 9단계의 성과를 크게 악화시킨 것은 분명하다. 둘째, 7단계(종가선+MA20+MA60)가 전체 기간 0.34% 에서 2.36% 로 상승하며, 20일과 6ㅇ일의 이중 이동평균선 전략이 이례적 급등기를 제외하면 상대적으로 효과적이었음을 보여준다.

그러나 테스트 기간을 축소하더라도 H-L 전략이 매수보유(연율화 8.97%, 샤프비율 0.528)를 체계적으로 상회하지는 못한다. 양(+)의 H-L 수익률을 보이는 단계가 있으나 그 절대적 수준은 매수보유에 미치지 못하며, 어느 단계가 우월한지는 테스트 기간에 따라 달라진다. 이는 CNN의 횡단면적 종목 선별 능력이 KOSPI 200에서 근본적으로 한계가 있음을 재확인한다. 2025 - 2026년의 이례적 급등이 결과를 일부 악화시킨 것은 사실이나, 그것을 제거한다 하더라도 Jiang et al. (2023) 이 미국 시장에서 보고한 수준의 예측력은 재현되지 않는다.[14)]

14) Jiang et al. (2023) 은 미국 시장에서 CNN 이미지 기반 10분위 H-L 전략이 등가중 포트폴리오 기준 연율화 샤프비율 최대 7.2를 달성한다고 보고한다. 또한 미국 데이터로 훈련된 CNN을 26개 국제 시장에 전이 학습(transfer learning)으로 적용한 결과, 한국 시장에서도 직전 5거래일의 가격 이미지로 향후 5거래일 수익률을 예측하는 구성(I5/R5)에서 시가총액가중 H-L 전략의 연율화 샤프비율이 2.07에 달한다고 보고한다.

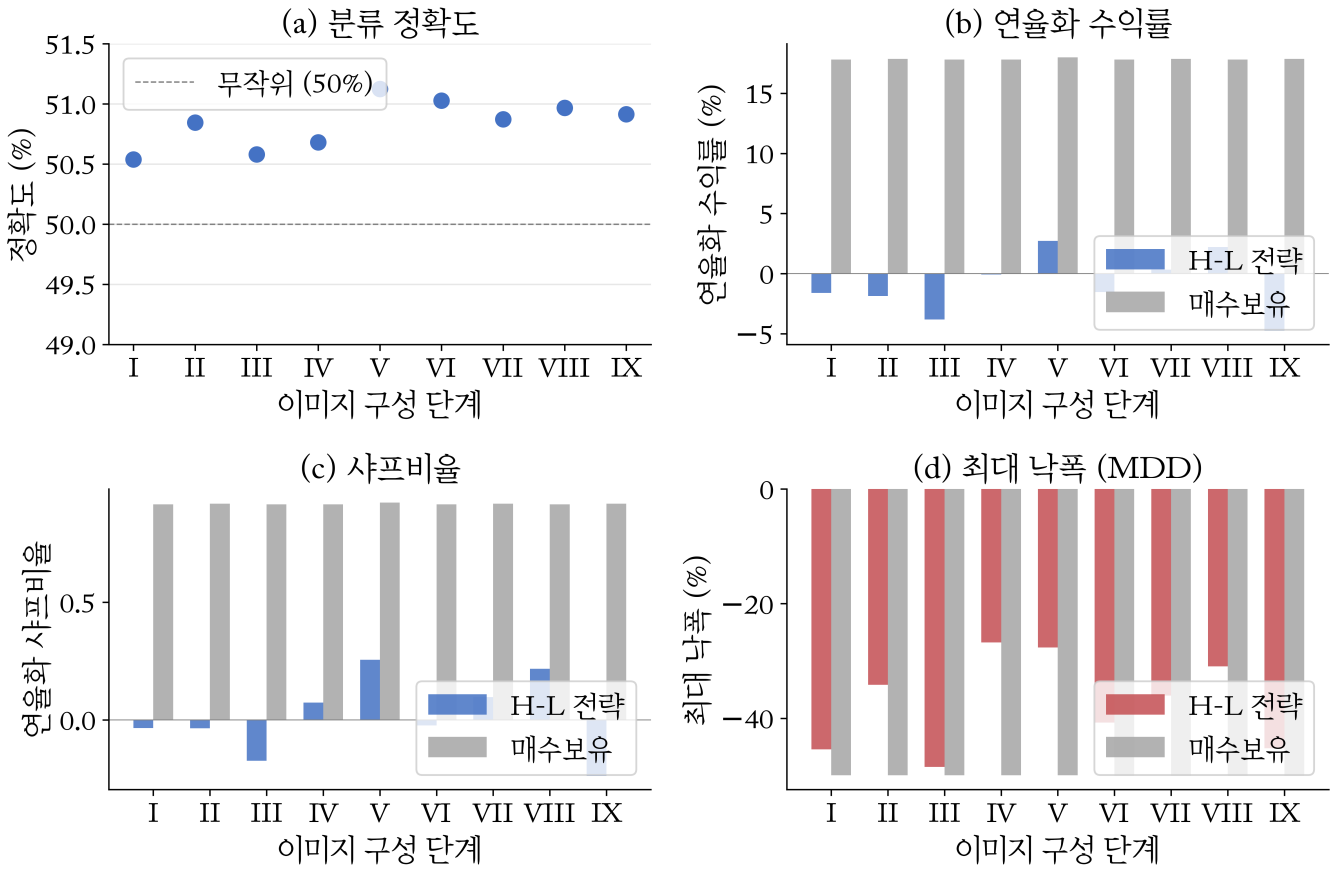

그림 2: 9단계 이미지 구성별 10분위 H-L 전략 종합 성과. (a) 분류 정확도(점선은 무작위 기준 50%), (b) H-L 전략과 매수보유의 연율화 수익률, (c) 연율화 샤프비율, (d) 최대 낙폭. 로마자 I - IX는 각각 1 - 9단계에 대응한다.

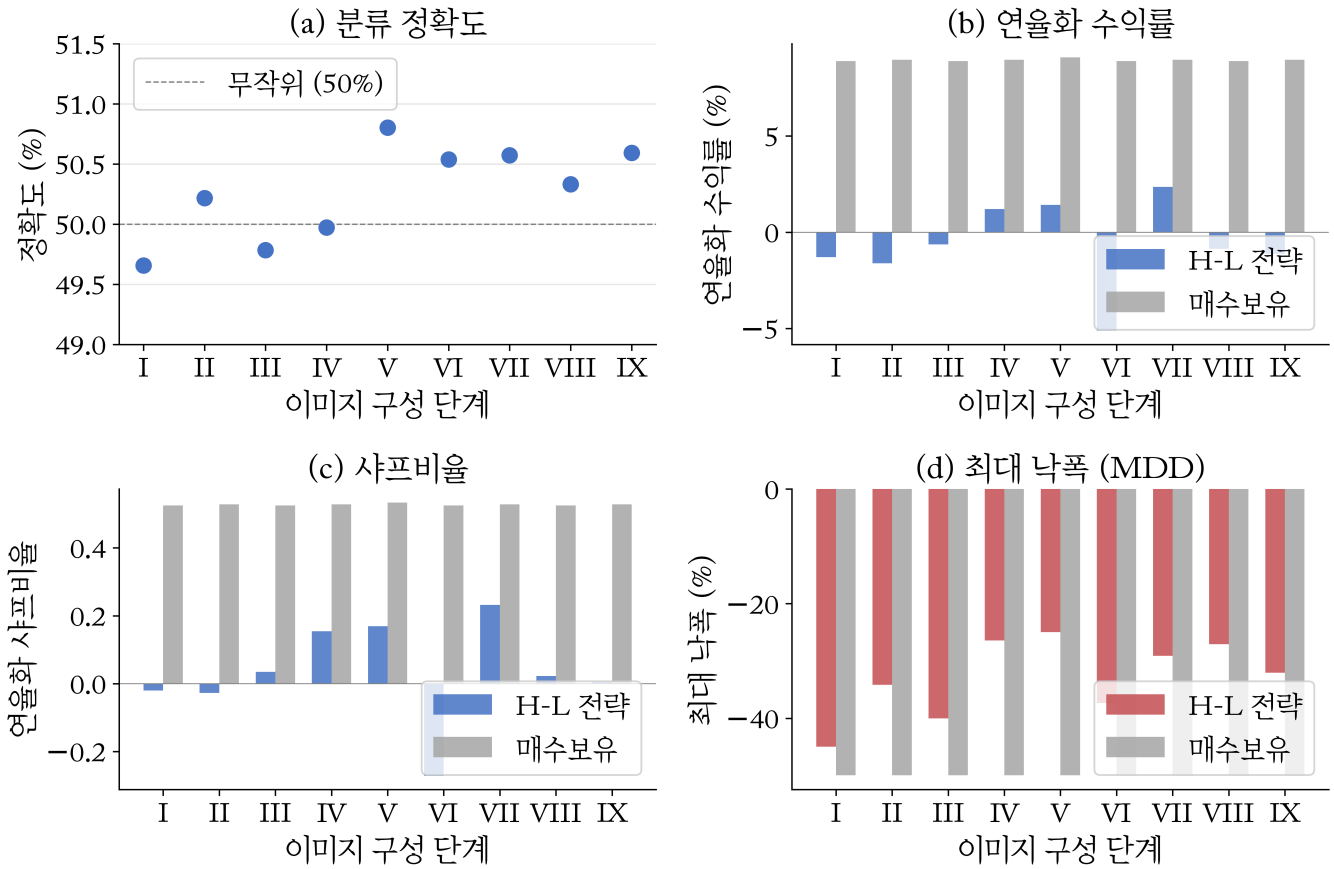

그림 3: 테스트 기간 2024년 말 한정 시 10분위 H-L 전략 종합 성과. (a) 분류 정확도(점선은 무작위 기준 50%), (b) H-L 전략과 매수보유의 연율화 수익률, (c) 연율화 샤프비율, (d) 최대 낙폭. 로마자 I - IX는 각각 1 - 9단계에 대응한다.

4.5 시장 구간별 성과

4.6 시장구간 변수 추출 R 청크 (시장구간표 앞에 배치)

코로나19 급락기(2020년 1 - 3월)에서 모든 단계의 H-L 전략은 매수보유 대비 양(+)의 초과수익률을 기록하였다. 종가선+거래량 가 +25.33%p 로 가장 크고 OHLC+MA20 가 +9.35%p 로 가장 작다. 시장 급락 시 CNN이 하락 확률이 높다고 판단한 종목(short 레그)이 실제로 더 크게 하락함으로써, long-short 스프레드가 상대적으로 양호하게 유지된 것이라고 판단한다.

그러나 코로나19 반등기(2020년 4월 - 2021년 6월)에서는 모든 단계에서 대규모 음(-)의 초과수익률이 관찰된다. OHLC+거래량+MA20 가 -75.53%p 로 가장 작고 OHLC 가 -114.02%p 로 가장 크다. 강한 상승장에서 CNN이 하락으로 분류한 종목(short 레그)도 함께 급등하면서 short 레그의 손실이 long 레그의 이익을 압도한 결과이다. AI 슈퍼사이클(2024 - 2025년)에서도 동일한 패턴이 반복되어, OHLC+거래량+MA20(-69.46%p)에서 OHLC+거래량+MA20+MA60(-96.34%p)에 이르는 대규모 초과 손실이 나타난다.

글로벌 긴축기(2022년 1 - 10월)에서는 대부분의 단계가 양(+)의 초과수익률을 보인다. 종가선+MA20 가 +23.67%p 로 가장 크다. 점진적 하락 국면에서는 종목 간 하락 속도의 차이가 있으며, CNN이 상대적으로 덜 하락할 종목과 더 하락할 종목을 어느 정도 구분할 수 있었음을 시사한다. 다만 7단계(종가선+MA20+MA60, +3.90%p)와 9단계(OHLC+거래량+MA20+MA60, +12.83%p)처럼 이동평균선이 이중으로 포함된 구성의 성과가 일관되지 않아, 이 국면에서도 CNN의 종목 선별 능력이 강건하다고 보기는 어렵다.

종합하면 H-L 전략은 시장 급락기에 상대적 방어 효과를 보이나, 상승기의 대규모 기회 손실이 이를 압도한다. 이러한 비대칭성은 KOSPI 대형주의 강한 동조화에 기인하는 것으로 판단된다. 상승 국면에서는 대부분의 종목이 함께 상승하여 short 레그가 구조적으로 불리해지고, 하락 국면에서만 종목 간 차별화가 가능해지기 때문이라고 판단한다.

표 4: 시장 구간별 CNN 매매 전략 성과

시장 구간	이미지 구성	전략 수익률	BH 수익률	초과수익률
코로나19 급락 (2020.01-2020.03)	I. 종가선	-8.36%	-30.39%	+22.03%p
	II. OHLC	-14.28%	-30.39%	+16.11%p
	III. 종가선+거래량	-5.05%	-30.39%	+25.33%p
	IV. OHLC+거래량	-16.06%	-30.39%	+14.33%p
	V. 종가선+MA20	-8.63%	-30.39%	+21.75%p
	VI. OHLC+MA20	-21.03%	-30.39%	+9.35%p
	VII. 종가선+MA20+MA60	-15.76%	-30.39%	+14.63%p
	VIII. OHLC+거래량+MA20	-15.86%	-30.39%	+14.53%p
	IX. OHLC+거래량+MA20+MA60	-18.27%	-30.39%	+12.12%p
코로나19 반등 (2020.04-2021.06)	I. 종가선	26.59%	128.50%	-101.91%p
	II. OHLC	14.48%	128.50%	-114.02%p
	III. 종가선+거래량	14.72%	128.50%	-113.78%p
	IV. OHLC+거래량	40.09%	128.50%	-88.41%p
	V. 종가선+MA20	44.57%	128.50%	-83.93%p
	VI. OHLC+MA20	33.68%	128.50%	-94.82%p
	VII. 종가선+MA20+MA60	47.75%	128.50%	-80.75%p
	VIII. OHLC+거래량+MA20	52.97%	128.50%	-75.53%p

표 4: 시장 구간별 CNN 매매 전략 성과 *(continued)*

시장 구간	이미지 구성	전략 수익률	BH 수익률	초과수익률
	IX. OHLC+거래량+MA20+MA60	37.03%	128.50%	-91.47%p
글로벌 긴축 (2022.01-2022.10)	I. 종가선	-6.11%	-15.72%	+9.61%p
	II. OHLC	3.13%	-15.37%	+18.50%p
	III. 종가선+거래량	6.93%	-15.72%	+22.65%p
	IV. OHLC+거래량	0.28%	-15.37%	+15.65%p
	V. 종가선+MA20	8.78%	-14.90%	+23.67%p
	VI. OHLC+MA20	5.87%	-15.72%	+21.59%p
	VII. 종가선+MA20+MA60	-11.47%	-15.37%	+3.90%p
	VIII. OHLC+거래량+MA20	3.34%	-15.72%	+19.06%p
	IX. OHLC+거래량+MA20+MA60	-2.54%	-15.37%	+12.83%p
AI 슈퍼사이클 (2024.01-2025.12)	I. 종가선	-14.59%	65.05%	-79.64%p
	II. OHLC	-9.17%	65.05%	-74.22%p
	III. 종가선+거래량	-28.33%	65.05%	-93.38%p
	IV. OHLC+거래량	-9.13%	64.41%	-73.53%p
	V. 종가선+MA20	-16.03%	65.05%	-81.08%p
	VI. OHLC+MA20	-10.16%	65.05%	-75.21%p
	VII. 종가선+MA20+MA60	-26.20%	65.05%	-91.25%p

표 4: 시장 구간별 CNN 매매 전략 성과 *(continued)*

시장 구간	이미지 구성	전략 수익률	BH 수익률	초과수익률
	VIII. OHLC+거래량+MA20	-4.41%	65.05%	-69.46%p
	IX. OHLC+거래량+MA20+MA60	-31.29%	65.05%	-96.34%p

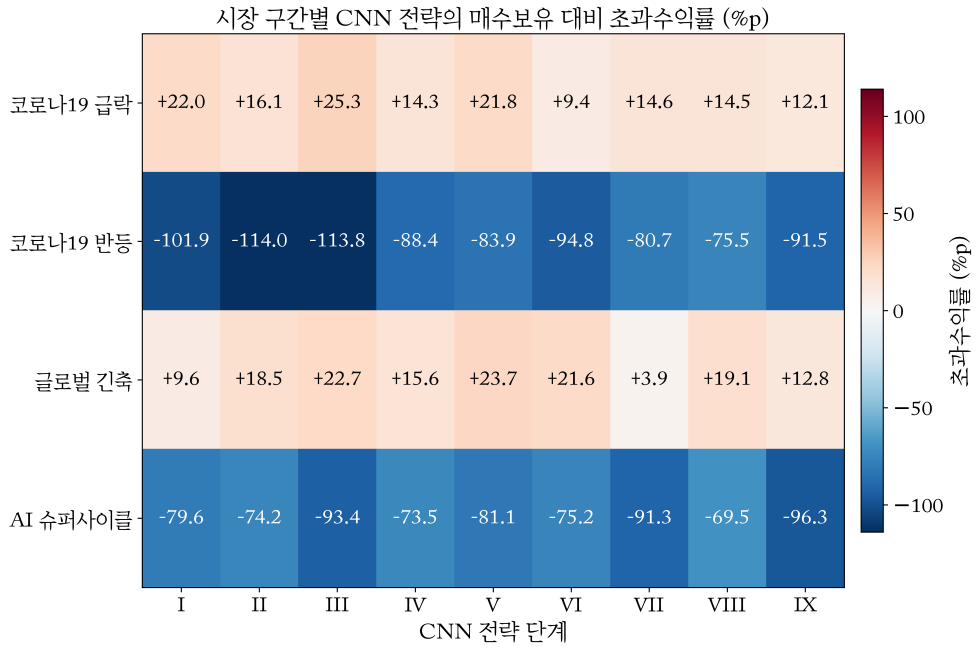

그림 4: 시장 구간별 CNN 매매 전략의 매수보유 대비 초과수익률(%p). 붉은색은 양의 초과수익률(매수보유 상회), 파란색은 음의 초과수익률(매수보유 하회)을 나타낸다. 로마자 I - IX는 각각 1 - 9단계에 대응한다.

4.7 기술적 매매의 근거 분석

CNN의 예측이 차트 이미지의 어느 영역에 근거하는가를 분석하는 것은 기술적 분석의 유효성과 그 오류가 어디서 비롯되는지를 검증하는 데 핵심적이다. 분류 정확도와 매매 전략 수익률은 CNN을 통해 기술적 매매의 성과를 사후적으로 측정하지만, 기술적 매매의 어느 지점에서, 어떤 정보을 어떻게 해석하고 있느지를 충분히 설명하지는 못한다. 비록 투자자가 직접 매매한 결과는 아니나, CNN이 투자자의 시각적 판단을 모사한다는 전제 하에서 CNN 모형의 판단 근거를 이해하는 것은 기술적 분석에 의존하는 투자 의사결정의 구조적 약점을 진단하는 데 유용하다. 특히 정분류와 오분류 사이에 주목 영역의 체계적 차이가 존재하는지를 분석하면, 기술적 매매가 성공하는 경우와 실패하는 경우에 CNN이 차트의 어떤 정보에 의존하는지 진단할 수 있다. 이는 투자자가 차트 정보를 시각적으로 해석할 때 어떤 요소에 과잉반응하고 어떤 요소를 간과하는지 유추하는 근거가 된다.

이러한 분석을 위해 Grad-CAM[15](Gradient-weighted Class Activation Mapping)(Selvaraju et al., 2017)을 적용한다. Grad-CAM은 CNN이 특정 예측을 내릴 때 입력 이미지의 어느 부분에 가장 크게 의존했는지를 색상으로 표현하는 기법이다.[16] 기술적으로, Grad-CAM은 CNN의 마지막 합성곱 레이어에서 특정 클래스에 대한 그래디언트를 역전파하여, 해당 클래스 판단에 기여한 입력 영역을 히트맵(heatmap)으로 시각화한다. 히트맵은 그림의 각 픽셀이 판단에 기여한 정도를 0에서 1 사이의 값으로 나타낸다.

Grad-CAM 분석의 대상으로는 8단계(OHLC+거래량+MA20)를 선택한다. 분류 정확도와 H-L 수익률에서 가장 양호한 성과를 보인 5단계(종가선+MA20)와 유사한 수준의 예측 성능을 보이면서, OHLC, 거래량, 이동평균선이 모두 포함되어 있어 각 정보 요소에 대한 CNN의 주목 양상을 관찰하기에 적합하다.

MA20의 추가가 CNN의 주목 영역에 미치는 영향을 분석하기 위해, MA20이 포함되지 않은 4단계(OHLC+거래량)와 8단계의 Grad-CAM 히트맵을 동일한 종목의 동일 시점 윈도우에 대해 나란히 비교한다. 종목과 시점은 8단계 CNN의 예측 확률이 각 범주의 중위수에 가장 가까운 사례로 선택한다. 결과는 다음과 같다.

(a) 정분류 상승(TP), 즉 실제 상승을 상승으로 정확히 예측한 경우에서 Stage 4는 가격 영역 전반에 걸쳐 붉은색이 비교적 넓게 퍼져 있다. Stage 8에서는 주목하는 영역이 MA20 선과 가격이 교차하는 윈도우 중반부로 이동하며,

---

15) Grad-CAM(Gradient-weighted Class Activation Mapping). 합성곱 신경망의 마지막 합성곱 레이어에서 특정 클래스에 대한 그래디언트를 역전파하여, 해당 판단에 기여한 입력 영역을 시각화하는 설명 가능한 AI(explainable AI) 기법으로, Selvaraju, Cogswell, Das, Vedantam, Parikh, and Batra (2017) 이 제안하였다. 구체적으로, 마지막 합성곱 레이어의 k번째 특징 맵 A^k 에 대해, 클래스 c 의 출력 y^c 의 그래디언트를 공간 차원에서 전역 평균 풀링하여 가중치 $\alpha_k^c = \frac{1}{Z}\sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$ 를 산출한다. 이 가중치로 특징 맵의 가중합을 구하고 ReLU를 적용하면 양의 영향만을 반영하는 히트맵 $L_{\text{Grad-CAM}}^c = \text{ReLU}\left(\sum_k \alpha_k^c A^k\right)$ 이 생성된다. 이 히트맵을 원본 이미지 크기(64×60)로 업샘플링하면 각 픽셀이 판단에 기여한 정도가 0에서 1 사이의 값으로 표현된다. 본 분석에서는 stage 9 이미지의 상단 51행(가격 영역)과 하단 13행(거래량 영역)에 대해 히트맵의 영역별 평균값을 비교하여, CNN이 가격과 거래량 중 어디에 더 주목하는지를 정량적으로 측정한다. 5회 독립 훈련된 CNN 모형 각각에 대해 Grad-CAM을 산출한 뒤 평균하며, 분류 범주별(정분류 상승, 정분류 하락, 거짓 양성, 거짓 음성, 코로나19 급락기)로 최대 500개 이미지에 대한 평균 히트맵을 생성한다.

16) 비유하면, 시험 문제를 푼 학생의 시선 추적 기록과 유사하다. 학생이 문제지의 어느 부분을 오래 응시했는지를 알면, 정답을 맞힌 경우에는 올바른 단서를 활용한 것이고, 오답인 경우에는 잘못된 단서에 현혹된 것으로 해석할 수 있다. Grad-CAM은 CNN에 대해 이와 동일한 역할을 수행한다.

가격이 MA20을 상향 돌파하는 지점에 강한 붉은색이 관찰된다. CNN이 MA20 기준선 대비 가격의 상대적 위치를 상승 판단의 핵심 근거로 활용하고 있음을 보여준다.

(b) 거짓 양성(FP), 즉 실제 하락을 상승으로 오판한 경우에서 Stage 4는 중앙부 인접한 좌측에 주목 영역이 분산되어 있다. Stage 8에서는 MA20 선 근처, 특히 MA20이 가격에 수렴하는 영역에 주목한다. CNN이 가격과 MA20의 수렴 패턴을 (a)와 유사한 상승 신호로 해석하였으나 실제로는 하락이 뒤따른 경우이다.

(c) 정분류 하락(TN), 즉 실제 하락을 하락으로 정확히 예측한 경우에서 Stage 4는 가격과 거래량에 걸쳐 주목 영역이 산재한다. Stage 8에서는 주목 영역이 가격 영역 우측의 MA20 선 위로 집중되며, 거래량 영역의 주목도가 현저히 감소한다. 가격이 MA20 아래로 하락하는 패턴을 하락의 근거로 참조하고 있음을 확인할 수 있다.

(d) 거짓 음성(FN), 즉 실제 상승을 하락으로 오판한 경우에서 Stage 4는 전반적으로 가격선을 따라 주목 영역이 산재되어 있다. Stage 8에서는 MA20 선을 따라 주목 영역이 집중된다. (c)와 유사하게 가격이 MA20을 하회하는 패턴에 반응하여 하락으로 판단한 것으로 보인다. 실제로는 이후 반등이 뒤따라, 결과적으로 MA20 선의 움직임에 과잉반응한 사례이다.

종합하면, MA20 추가로 인해 CNN이 주목하는 영역이 산발적인 가격 패턴에서 MA20 기준선 중심으로 이동하는 것이 확인된다. 분류 정확도 분석에서 MA20이 가장 큰 예측 기여를 보인 것의 시각적 근거를 제공한다.

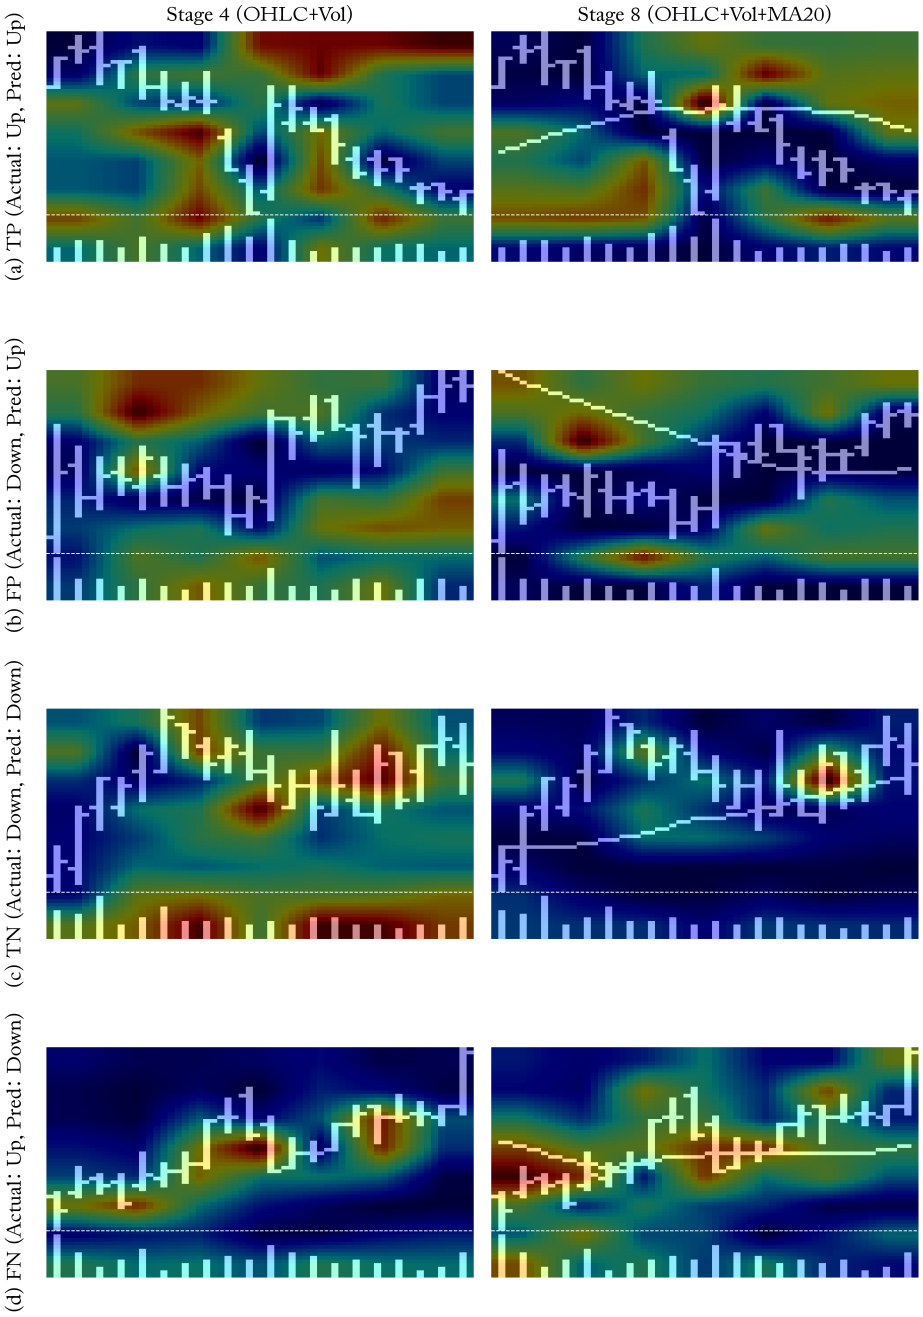

그림 5: Grad-CAM 개별 사례. 좌측은 Stage 4(OHLC+거래량), 우측은 Stage 8(OHLC+거래량+MA20)이다. (a) 정분류 상승, (b) 거짓 양성, (c) 정분류 하락, (d) 거짓 음성. 붉은색 영역은 CNN이 강하게 주목한 부분이다. 흰색 점선은 가격 영역(상단)과 거래량 영역(하단)의 경계이다. 동일한 이미지에 대해 MA20 추가로 인한 주목 영역의 변화를 비교할 수 있다.

이러한 개별 사례에서 관찰되는 주목 패턴이 체계적인 것인지를 확인하기 위해, 범주별로 최대 500개 이미지의 평균 주목도를 산출한다. 4단계와 8단계 이미지의 가격 영역(51행)을 비교하여 8단계에만 존재하는 픽셀을 MA20 마스크로 정의한다. MA20 마스크 픽셀은 가격 영역 전체의 2.59%에 불과하다. 이 마스크를 이용하여 8단계의 Grad-CAM 히트맵에서 MA20 영역, 비MA20 가격 영역(OHLC 바), 거래량 영역의 평균 주목도를 범주별로 산출한다.

표 5: 분류 범주별 MA20 마스크 기반 Grad-CAM 주목도 (8단계)

분류	MA20	비MA20 가격	거래량	비율 (MA20/비MA20)	표본 수
TP	0.1899	0.2054	0.1811	0.92	500
FP	0.1900	0.2064	0.1846	0.92	500
TN	0.1691	0.1546	0.1427	1.09	500
FN	0.1714	0.1545	0.1419	1.11	500

하락 예측(TN 1.09, FN 1.11)에서 MA20/비MA20 비율이 1을 상회하여 CNN이 MA20 선에 상대적으로 더 주목하는 반면, 상승 예측(TP 0.92, FP 0.92)에서는 비율이 1 미만으로 OHLC 바에 대한 주목이 더 크다. 이는 앞서 개별 사례에서 관찰된 패턴, 즉 CNN이 상승을 판단할 때는 OHLC 바가 MA20을 상향 돌파하는 형태에, 하락을 판단할 때는 가격이 MA20 아래에 위치하는 패턴에 각각 의존하는 비대칭적 전략을 정량적으로 확인한다.

MA20 마스크 픽셀이 가격 영역의 2.59%에 불과한데도 비MA20 영역에 버금가는 주목도를 보인다는 점은, 면적 대비 CNN의 주목 밀도가 MA20 선에 극도로 집중되어 있음을 의미한다. 분류 정확도 분석에서 MA20이 예측 기여가 가장 큼을 재확인한다.

결론적으로 Grad-CAM 분석은 두 가지 발견을 제공한다. 첫째, MA20 추가로 인해 CNN의 주목이 산발적 가격 패턴에서 MA20 기준선 중심으로 체계적으로 이동하며, CNN은 상승 판단 시 가격의 MA20 상향 돌파에, 하락 판단 시 가격의 MA20 하회에 각각 의존하는 비대칭적 주목 전략을 학습한다. 둘째, 거짓 양성(FP)은 가격과 MA20의 수렴을 상승 신호로 과잉 해석한 결과이고, 거짓 음성(FN)은 가격의 MA20 하회에 과잉반응하여 이후의 반등을 포착하지 못한 결과

이다. 이는 가격과 MA20의 상대적 위치라는 단순한 패턴만으로는 미래 주가의 방향을 체계적으로 예측하기 어렵다는 것을 뜻한다. CNN의 예측 실패는 이동평균선을 매매 신호로 이용하는 기술적 매매 투자자가 직면하는 문제이기도 하다.

참고 문헌

Xavier Glorot and Yoshua Bengio. Understanding the difficulty of training deep feed-forward neural networks. In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, pages 249–256, 2010.

Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

Shihao Gu, Bryan Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.

Jingwen Jiang, Bryan Kelly, and Dacheng Xiu. (Re-)imag(in)ing price trends. *The Journal of Finance*, 78(6):3193–3249, 2023.

Michael Parkinson. The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1):61–65, 1980.

Ramprasaath R Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 618–626, 2017.